Python for Data Analysis 13장 Quiz 보고서

1. 개요

Wes McKinney의 *Python for Data Analysis* 13장 예제 5개(Bitly, MovieLens, 미국 신생아 이름, USDA 식품, FEC 후원금)를 학습하고, 각 Quiz를 pandas로 풀었다. 데이터는 저자의 GitHub(`3rd-edition` 브랜치의 `datasets`)에서 코드로 직접 내려받으므로 노트북(`quiz_with_answers.ipynb`)은 처음부터 끝까지 실행된다. 추가로 5개 Quiz를 한 화면에서 조작해 볼 수 있는 Gradio 앱(`app.py`)을 구현했다.

2. Quiz별 풀이와 결과

Quiz 1. Bitly 1.USA.gov

- 풀이: `a`가 결측인 행을 제거하고, `tz`의 결측은 "Missing", 빈 문자열은 "Unknown"으로 바꾼 뒤 `np.where`로 `os` 열(Windows / Not Windows)을 만들었다. 접속 상위 10개 시간대를 `value_counts().nlargest(10)`으로 고르고 `groupby(["tz","os"]).size()`로 건수를 센 다음, `transform("sum")`으로 시간대별 비율을 계산했다.
- 결과: Windows 비율 상위 5곳은 Pacific/Honolulu(100%), Asia/Tokyo(94.6%), America/New_York(72.9%), America/Chicago(71.3%), America/Los_Angeles(66.0%)이다. Honolulu와 Tokyo는 접속이 36건, 37건뿐이라 비율이 극단적이며, 접속이 가장 많은 New_York(1,251건)은 약 73%이다.

Quiz 2. MovieLens 1M

- 풀이: users, ratings, movies를 `merge`로 합치고 평점 250개 이상인 영화만 남겼다. `pivot_table`로 영화별 성별 평균을 구해 `diff = M − F`를 만들고, `str.split("|")`와 `explode`로 장르별 행으로 펼친 뒤 `abs().groupby(genre).idxmax()`로 장르마다 차이가 가장 큰 영화를 골랐다.
- 결과: 여성이 더 높게 평가한 차이가 가장 큰 영화는 Dirty Dancing(−0.83, Romance·Musical), 남성이 더 높게 평가한 영화는 The Good, The Bad and The Ugly(+0.73, Action·Western)이다. 여러 장르에 속한 영화는 장르마다 중복해서 나타난다.

Quiz 3. US Baby Names 1880–2010

- 풀이: `decade = year // 10 * 10`을 만들고 이름·10년대·성별 출생수를 집계해 `unstack`으로 여아 비율(F/(F+M))을 구했다. 1900년대와 2000년대 모두 출생수 500명 이상, 1900년대 여아 비율 20% 미만, 2000년대 80% 초과를 동시에 만족하는 이름을 찾았다.
- 결과: 남자 이름에서 여자 이름으로 바뀐 이름은 Aubrey(10.5% → 95.1%)와 Leslie(11.3% → 97.0%) 두 개이다.

Quiz 4. USDA Food Database

- 풀이: 중첩 JSON을 `info`와 `nutrients`로 정규화해 `id`로 병합(`ndata`)하고 단백질 행만 추출했다. 식품군별 중위수를 `transform("median")`으로 모든 행에 붙여 `ratio = value / fg_median`을 계산하고, 중위수가 0보다 크면서 ratio가 2 이상인 식품만 남긴 뒤 `agg`로 개수와 최대 ratio, `idxmax`로 최대 식품을 구했다.

- 결과: 개수는 Vegetables and Vegetable Products(139개), Beverages(106개), Legumes and Legume Products(101개) 순이다. 최대 ratio는 Beverages가 358.6배(Cocoa mix, 25.1g)로 가장 큰데, 음료의 단백질 중위수가 약 0.07g으로 거의 0이기 때문이며 Fats and Oils가 124.6배로 그다음이다.

Quiz 5. 2012 FEC 후원금

- 풀이: 환불(금액 ≤ 0)을 제외하고 Obama·Romney 후원만 남긴 뒤, "INFORMATION REQUESTED…" 3종은 "NOT PROVIDED", "C.E.O."는 "CEO"로 통일했다. 후보별·주별 합계를 구해 총액 10만 달러 초과 주만 남기고 주별 비율을 계산했으며, 주마다 후원금이 가장 큰 직업을 `top_occupation`으로 붙였다.
- 결과: Obama 비율이 가장 높은 주는 VT(94.7%), ME(90.9%), PR(88.1%), HI(87.7%), MN(85.6%)이다. 이 지역의 최다 후원 직업은 PR(PRESIDENT)을 제외하면 모두 RETIRED(은퇴자)이다.

3. Gradio 앱

`app.py`는 탭 5개(Quiz 1~5)로 구성되며, 탭마다 Quiz의 기준값을 슬라이더로 바꿀 수 있다(상위 시간대 개수, 최소 평점 수 250, 최소 출생수 500과 여아 비율 20%·80%, 최소 ratio 2, 주별 최소 후원액 10만 달러). 실행 버튼을 누르면 결과 표와 그래프가 함께 갱신된다. 데이터는 처음 실행할 때만 내려받아 `data` 폴더에 저장하고, 이후에는 메모리에 캐시해 빠르게 응답한다. 실행은 `pip install gradio pyarrow` 후 `python app.py`이며, 브라우저에서 `http://127.0.0.1:7860`으로 접속한다.

4. 결론

`transform`은 그룹 통계를 모든 행에 붙여 비율을 계산할 때(Quiz 1, 4), `unstack`은 긴 표를 넓은 표로 바꿀 때(Quiz 3, 5), `explode`는 리스트가 든 열을 행으로 펼칠 때(Quiz 2) 핵심이었다. 또한 건수가 적은 그룹(Honolulu, Tokyo)이나 중위수가 거의 0인 그룹(Beverages)은 비율이 과장될 수 있으므로, 비율은 표본 크기와 함께 해석해야 한다는 점을 확인했다.