영화 대사 코퍼스 기반 텍스트 분류 분석 보고서

스타워즈 대사 기반 선(Good=1) / 악(Bad=0) 캐릭터 이진 분류 및 머신러닝 모델 비교 (소규모 vs 대규모)

1. 데이터, 라벨 정의, 정제

라벨 규칙(과제용): Good = LUKE, LEIA / Bad = DARTH VADER, EMPEROR. 캐릭터 기준의 라벨링이며 대사의 실제 감정이나 도덕성을 뜻하지 않고, 결과를 일반적인 감정 분석 성능으로 해석하지 않는다.

	원본	정제 후	Good	Bad	Bad 비율	불균형(Good:Bad)	제거한 완전 중복
소규모 (100lines)	125	121	97 (LUKE)	24 (EMPEROR)	19.8%	4.0 : 1	4
대규모 (1000lines)	552	539	515 (LUKE, LEIA)	24 (EMPEROR)	4.5%	21.5 : 1	13

정제: 결측·빈 대사 제거, 공백 정리, 같은 라벨의 완전 중복 제거(소문자 변환과 문장부호 제거 같은 강한 정규화는 하지 않음). 대소문자·문장부호만 다른 유사 중복은 지우지 않고 그룹으로 표시해 교차검증에서 같은 쪽에 두었다(데이터 누출 방지).

데이터 점검에서 발견한 문제(결과 해석에 영향):

- 두 파일 모두 **DARTH VADER 대사가 없어** Bad는 EMPEROR 24개뿐이다. 모델이 '악한 대사'가 아니라 황제의 말투를 학습할 수 있다.
- 영화 '듄'의 황제 대사, 스타워즈에 없는 이름(Harry, Delly 등)이 든 LUKE 대사가 섞여 있다. 영화별 어휘가 단서가 될 수 있다.
- 대규모 파일은 1,000개에 못 미치며(교수님 확인 후 제공 파일 그대로 사용), 추가된 대사는 모두 Good이다. 소규모 파일은 대규모 파일의 부분집합에 가까워 두 실험이 독립적이지 않다.
- Bad 대사가 훨씬 길다(중앙값 약 14단어, Good은 5~6단어). 길이만으로도 일부 분류가 가능하다. 같은 대사 "Yes."가 Good과 Bad 양쪽에 있다(라벨 충돌 1건).

실험 방법: TF-IDF(unigram)를 기본 벡터화로 하고 벡터화와 모델을 하나의 Pipeline으로 묶었다. Bad가 24개뿐이라 단일 분할 대신 **층화 5-fold 그룹 교차검증을 5회 반복(25 fold)**하여 평균 ± 표준편차를 보고한다. 모델은 Logistic Regression, Linear SVC, Multinomial NB, Random Forest, HistGradientBoosting이며 기본 설정과 `class_weight='balanced'` (NB는 fit_prior=False)를 비교했다. 하이퍼파라미터 탐색은 중첩 교차검증 안에서만 수행했다. 기준선으로 "모두 Good 예측"과 "대사 길이만 사용"을 넣었다.

2. 결과 요약 (TF-IDF, 25 fold 평균)

데이터	설정 / 모델	Accuracy	Bad Precision	Bad Recall	Bad F1	Macro-F1 (± 표준편차)
대규모	기준선: 모두 Good 예측	0.955	0.000	0.000	0.000	0.489 ± 0.001
대규모	기본 설정 Logistic Regression / NB / RF	0.955	0.000	0.000	0.000	0.489 ± 0.001
대규모	balanced Logistic Regression	0.945	0.422	0.376	0.357	0.664 ± 0.087
대규모	balanced Linear SVC	0.952	0.493	0.324	0.356	0.666 ± 0.098
대규모	balanced Multinomial NB	0.891	0.101	0.156	0.120	0.531 ± 0.078
대규모	balanced Random Forest	0.955	0.000	0.000	0.000	0.488 ± 0.001
대규모	balanced HistGradientBoosting	0.915	0.041	0.040	0.037	0.496 ± 0.041
대규모	**balanced + 탐색 Linear SVC (최종 선정)***	**0.948**	**0.439**	**0.393**	**0.370**	**0.671 ± 0.108**
소규모	기준선: 모두 Good 예측	0.802	0.000	0.000	0.000	0.445 ± 0.005
소규모	balanced Logistic Regression	0.853	0.673	0.590	0.607	0.758 ± 0.094
소규모	balanced Linear SVC	0.871	0.773	0.546	0.610	0.766 ± 0.100
소규모	balanced Multinomial NB	0.786	0.492	0.724	0.574	0.714 ± 0.075
소규모	balanced Random Forest	0.826	0.440	0.124	0.190	0.546 ± 0.123
소규모	balanced HistGradientBoosting	0.706	0.325	0.452	0.365	0.586 ± 0.108
소규모	기준선: 길이만 사용 (balanced)	0.709	0.392	0.736	0.493	0.641 ± 0.113

* 탐색 모델은 바깥 반복 3회(15 fold) 평균이다. 선정 규칙: 대규모에서 Macro-F1이 최고점과 0.02 이내인 모델 중 Bad F1이 가장 높은 모델. 재현: random_state 42~46, 노트북 전체 실행 기준.

3. 보고서 질문에 대한 답

① 데이터를 늘렸을 때 성능이 향상되었는가? 안정적이 되었는가?

아니다. 기본 설정의 Accuracy는 0.80에서 0.955로 올랐지만 이는 Good 대사만 늘어난 착시이다(모두 Good으로 예측해도 0.955). balanced를 적용한 Macro-F1은 Logistic Regression이 0.758에서 0.664로, Linear SVC가 0.766에서 0.666으로 오히려 낮아졌고 표준편차(약 0.09~0.10)도 줄지 않았다. 이유: Bad는 24개로 고정되고 Good만 늘어 불균형이 4:1에서 21.5:1로 심해졌고(LEIA 추가로 Good 구성도 달라짐), Bad를 학습할 정보는 늘지 않았으며, 검증 fold당 Bad가 약 5개라 Recall이 한 개당 약 20%p 흔들린다.

② Accuracy와 Bad Recall이 다른 결론을 준 사례가 있는가?

있다. 대규모 기본 설정의 다섯 모델은 Accuracy가 0.951~0.957로 매우 높지만 Bad Recall은 0~0.042로 황제 대사를 거의 찾지 못했다. balanced를 적용하면 Logistic Regression의 Bad Recall이 0에서 0.376으로 올라가는 대신 Accuracy는 0.955에서 0.945로, Naive Bayes는 0.955에서 0.891로 내려간다. 최종 모델의 Accuracy(0.948)도 모두 Good 예측 기준선(0.955)보다 낮다. 그래서 Accuracy만으로 모델을 고르지 않았다.

③ CountVectorizer와 TF-IDF 중 무엇이 더 좋았는가?

선형 모델에서 TF-IDF가 일관되게 앞섰다(balanced, Macro-F1: Logistic Regression 소규모 0.758 대 0.708, 대규모 0.664 대 0.634 / Linear SVC 0.766 대 0.676, 0.666 대 0.628). 소규모 Linear SVC는 25 fold 중 18개에서 TF-IDF가 이겼다. 다만 차이는 fold 간 표준편차(약 0.09~0.14)보다 작다. 대사가 짧고 I, you, the 같은 공통 단어가 많아, 흔한 단어의 비중을 낮추고(IDF) 길이를 정규화(L2)하는 TF-IDF가 유리하다는 설명과 맞다(교수님 제공 엑셀 예제로 수식을 직접 확인함). NB, Random Forest, HistGradientBoosting은 대규모에서 Count가 조금 높았으나 모두 기준선 수준이라 의미가 작다.

④ 다섯 모델 중 가장 균형 잡힌 모델과 판단 지표는?

Linear SVC와 Logistic Regression이 가장 균형 잡혔고 둘은 통계적으로 구분되지 않는다(대규모 Macro-F1 차이 −0.002, 윌콕슨 $p = 0.76$). Logistic Regression이 Bad Recall이 조금 높다(0.376 대 0.324, $p = 0.039$). Naive Bayes는 소규모에서 Bad Recall이 높았지만(0.724) Precision이 낮고 대규모에서 무너졌으며, Random Forest와 HistGradientBoosting는 balanced에서도 Bad를 거의 찾지 못했다(희소 고차원 텍스트와 Bad 24개의 한계). 판단 지표는 **Bad Recall, Bad F1, Macro-F1, 표준편차와 같은 fold 짝 비교**이다. 최종 모델은 규칙에 따라 **TF-IDF + Linear SVC(balanced, 탐색)**이다(Macro-F1 0.671, Bad Recall 0.393, Bad F1 0.370). 하이퍼파라미터 탐색의 이득은 ±0.02 안팎으로 표준편차보다 훨씬 작았다.

오분류 사례 (최종 모델)	실제	예측	추정 원인
Everything is proceeding as I have foreseen.	Bad	Good	흔한 단어뿐이라 Bad를 특징짓는 단어가 없음
I shall want telepathy during his visit and a report...	Bad	Good	'듄' 대사로 보이며 학습에 없던 어휘
I can assure you...	Bad	Good	매우 짧아 정보 부족
Yes. (LEIA)	Good	Bad	'yes'가 가장 강한 Bad 단어로 학습됨(황제의 'Yes' 대사)
Vader is here...now, on this moon. (LUKE)	Good	Bad	'Vader'가 들어 있어 황제 대사와 유사

Bad 24개 중 5개는 모든 반복에서 맞히고 10개는 모든 반복에서 놓쳤다. 모델이 쓴 단어: Bad 쪽 yes, assure, must, skywalker, force, navigator(듄) / Good 쪽 what, don, know, why, father, leia.

⑤ 사전학습 문장 임베딩이나 생성형 모델이 도움이 되었는가?

이번에는 실행하지 못했다(실행 환경에서 모델을 내려받을 수 없었음. 노트북의 USE_SBERT 옵션으로 실행 가능). 대신 같은 어휘 정보를 압축한 밀집 표현(TF-IDF→SVD 50차원)을 비교했으나 이득이 없었다(Macro-F1 소규모 0.756, 대규모 0.581). KNN(코사인)도 k에 민감했고 중첩 검증 기준 Macro-F1이 0.724(소규모), 0.656(대규모)로 선형 모델과 비슷하거나 낮았다. PCA 두 성분의 설명 분산은 7.8%/3.8%에 그쳐 Good과 Bad가 겹쳤고, 스펙트럴 바이클러스터링($k = 2$~6)도 ARI가 0에 가까워(최고 0.021) 단어 군집이 라벨과 맞지 않았다. 임베딩은 문맥과 말투를 담아 도움이 될 가능성이 있고 538개 규모에서는 비용도 작지만, Bad가 24개이고 황제 한 명뿐이라 효과는 직접 실험으로 확인해야 한다(이는 결과가 아니라 가설이다).

⑥ 이번 실험의 한계와 개선 방안은?

- **한계:** Bad 24개(모두 EMPEROR, VADER 없음) · 다른 영화 대사 혼입 · 길이와 영화별 어휘가 라벨과 얽힘 · 모든 지표가 Bad 24개에 기댄 교차검증이라 표준편차가 크고 모델 간 작은 차이는 구분되지 않음 · 단일 대사 단위라 대화 맥락 없음 · 임베딩·생성형 모델 미실행.
- **개선:** Cornell 원본에서 영화를 스타워즈로 제한하고 VADER를 포함해 Bad를 100~200개 이상으로 확보 · 이전 2~3턴의 대사를 함께 입력 · 길이를 통제하거나 타 영화 대사를 제거한 대조 실험 · Sentence-BERT 임베딩과 소형 LLM을 같은 분할에서 비교 · 화자 단위 분할로 일반화 점검.